直接pip install 安装flash-attn会遇见各种报错，尝试了很多方法：

1、通过从 GitHub Releases 页面下载正确的轮文件

https://github.com/Dao-AILab/flash-attention/releases

选择合适版本，如本项目要求的python 3.10, cuda 12.4, torch 2.4将选择以下版本

https://github.com/Dao-AILab/flash-attention/releases/download/v2.8.3/flash_attn-2.8.3+cu12torch2.4cxx11abiTRUE-cp310-cp310-linux_x86_64.whl

命令为：`pip install https://github.com/Dao-AILab/flash-attention/releases/download/v2.8.3/flash_attn-2.8.3+cu12torch2.4cxx11abiTRUE-cp310-cp310-linux_x86_64.whl`

```
conda install pytorch==2.4.0 torchvision==0.19.0 torchaudio==2.4.0 pytorch-cuda=12.4 -c pytorch -c nvidia
```

运行bash.sh后报如下错：

```
(magi) root@7s6go2hlu6o82-0:/duwenqing/JIANGQINRU/MAGI-1# bash example/4.5B/run.sh
Traceback (most recent call last):
  File "/duwenqing/JIANGQINRU/MAGI-1/inference/pipeline/entry.py", line 18, in <module>
    from inference.pipeline import MagiPipeline
  File "/duwenqing/JIANGQINRU/MAGI-1/inference/pipeline/__init__.py", line 15, in <module>
    from .pipeline import MagiPipeline
  File "/duwenqing/JIANGQINRU/MAGI-1/inference/pipeline/pipeline.py", line 20, in <module>
    from inference.model.dit import get_dit
  File "/duwenqing/JIANGQINRU/MAGI-1/inference/model/dit/__init__.py", line 15, in <module>
    from .dit_model import get_dit
  File "/duwenqing/JIANGQINRU/MAGI-1/inference/model/dit/dit_model.py", line 39, in <module>
    from .dit_module import CaptionEmbedder, FinalLinear, LearnableRotaryEmbeddingCat, TimestepEmbedder, TransformerBlock
  File "/duwenqing/JIANGQINRU/MAGI-1/inference/model/dit/dit_module.py", line 27, in <module>
    from flash_attn import flash_attn_varlen_func
  File "/duwenqing/miniconda3/envs/magi/lib/python3.10/site-packages/flash_attn/__init__.py", line 3, in <module>
    from flash_attn.flash_attn_interface import (
  File "/duwenqing/miniconda3/envs/magi/lib/python3.10/site-packages/flash_attn/flash_attn_interface.py", line 15, in <module>
    import flash_attn_2_cuda as flash_attn_gpu
ImportError: /lib/x86_64-linux-gnu/libc.so.6: version `GLIBC_2.32' not found (required by /duwenqing/miniconda3/envs/magi/lib/python3.10/site-packages/flash_attn_2_cuda.cpython-310-x86_64-linux-gnu.so)
```

系统是ubuntu20.04，安装上面版本依旧无法运行，glibc（GNU C库）版本过低，而 `flash-attn` 的二进制扩展模块（`.so` 文件）是在一个 **glibc ≥ 2.32** 的系统上编译的

```
ldd --version
```

输出：

```
ldd (Ubuntu GLIBC 2.31-0ubuntu9.14) 2.31
```

由于是直接根据python 3.10, cuda 12.4, torch 2.4匹配到的是2.8.3版本，而requirement.txt中是2.4.2，可能安装2.4.2能解决

2、安装requirement.txt中的2.4.2版本（可能有用，也可能没用），根据chatgpt提示，装预编译 wheel：

```
(magi) root@7s6go2hlu6o82-0:/duwenqing# pip install flash-attn==2.4.2 --index-url
https://flash-attention-wheels.s3.us-west-2.amazonaws.com/whl/cu124/torch2.4/index.html
Looking in indexes: https://flash-attention-wheels.s3.us-west-
2.amazonaws.com/whl/cu124/torch2.4/index.html, https://pypi.ngc.nvidia.com

ERROR: Could not find a version that satisfies the requirement flash-attn==2.4.2 (from
versions: none)
ERROR: No matching distribution found for flash-attn==2.4.2
(magi) root@7s6go2hlu6o82-0:/duwenqing# nvcc -V
nvcc: NVIDIA (R) Cuda compiler driver
Copyright (c) 2005-2025 NVIDIA Corporation
Built on Wed_Apr__9_19:24:57_PDT_2025
Cuda compilation tools, release 12.9, V12.9.41
Build cuda_12.9.r12.9/compiler.35813241_0
```

这个输出表明，现在的 系统 CUDA 编译器（12.9）比 PyTorch 的 runtime CUDA（12.4）高一个大版本。这会导致 flash-attn 的 wheel 源（cu124/torch2.4）找不到匹配项，因为官方还没提供针对 CUDA 12.9 + Torch 2.4 的预编译包。

所以，保持 Torch 2.4，不动，降级 CUDA toolkit：

```
conda install -c nvidia cuda-toolkit=12.1
```

还是不行

```
(magi) root@7s6go2hlu6o82-0:/duwenqing# pip install flash-attn==2.4.2 --index-url
https://flash-attention-wheels.s3.us-west-2.amazonaws.com/whl/cu121/torch2.4/index.html

Looking in indexes: https://flash-attention-wheels.s3.us-west-
2.amazonaws.com/whl/cu121/torch2.4/index.html, https://pypi.ngc.nvidia.com
ERROR: Could not find a version that satisfies the requirement flash-attn==2.4.2 (from
versions: none)
ERROR: No matching distribution found for flash-attn==2.4.2
```

下面来自GitHub Releases 页面：

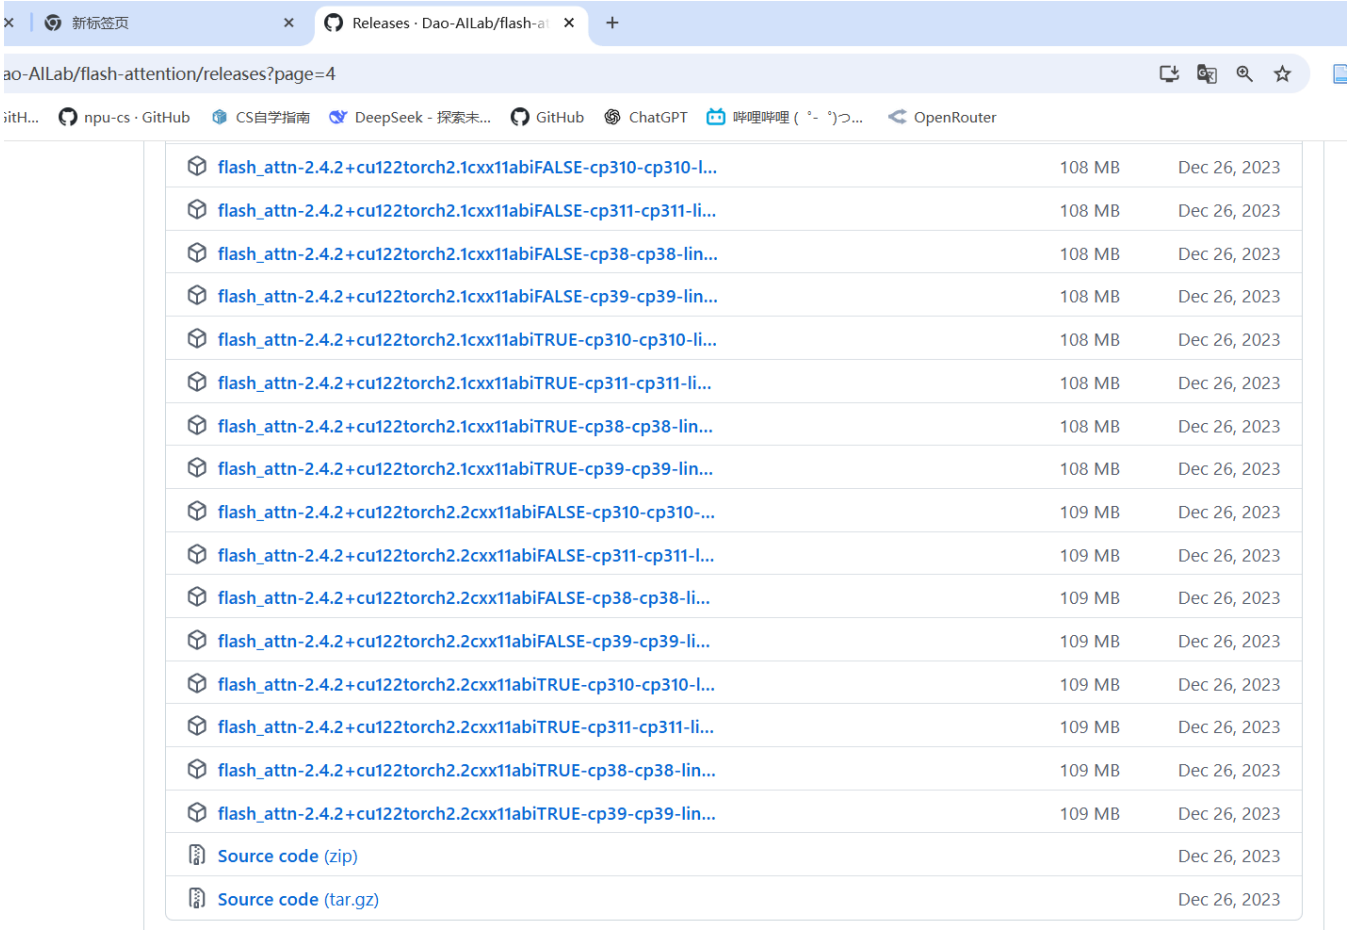

flash_attn-2.4.2+cu122torch2.1cxx11abiFALSE-cp310-cp310-l...	108 MB	Dec 26, 2023
flash_attn-2.4.2+cu122torch2.1cxx11abiFALSE-cp311-cp311-li...	108 MB	Dec 26, 2023
flash_attn-2.4.2+cu122torch2.1cxx11abiFALSE-cp38-cp38-lin...	108 MB	Dec 26, 2023
flash_attn-2.4.2+cu122torch2.1cxx11abiFALSE-cp39-cp39-lin...	108 MB	Dec 26, 2023
flash_attn-2.4.2+cu122torch2.1cxx11abiTRUE-cp310-cp310-li...	108 MB	Dec 26, 2023
flash_attn-2.4.2+cu122torch2.1cxx11abiTRUE-cp311-cp311-li...	108 MB	Dec 26, 2023
flash_attn-2.4.2+cu122torch2.1cxx11abiTRUE-cp38-cp38-lin...	108 MB	Dec 26, 2023
flash_attn-2.4.2+cu122torch2.1cxx11abiTRUE-cp39-cp39-lin...	108 MB	Dec 26, 2023
flash_attn-2.4.2+cu122torch2.2cxx11abiFALSE-cp310-cp310-...	109 MB	Dec 26, 2023
flash_attn-2.4.2+cu122torch2.2cxx11abiFALSE-cp311-cp311-l...	109 MB	Dec 26, 2023
flash_attn-2.4.2+cu122torch2.2cxx11abiFALSE-cp38-cp38-li...	109 MB	Dec 26, 2023
flash_attn-2.4.2+cu122torch2.2cxx11abiFALSE-cp39-cp39-li...	109 MB	Dec 26, 2023
flash_attn-2.4.2+cu122torch2.2cxx11abiTRUE-cp310-cp310-l...	109 MB	Dec 26, 2023
flash_attn-2.4.2+cu122torch2.2cxx11abiTRUE-cp311-cp311-li...	109 MB	Dec 26, 2023
flash_attn-2.4.2+cu122torch2.2cxx11abiTRUE-cp38-cp38-lin...	109 MB	Dec 26, 2023
flash_attn-2.4.2+cu122torch2.2cxx11abiTRUE-cp39-cp39-lin...	109 MB	Dec 26, 2023
Source code (zip)		Dec 26, 2023
Source code (tar.gz)		Dec 26, 2023

如果要装2.4.2，那么torch和cuda版本都不能按照README中来，可能最后项目也运行不起来

以下是MAGI-1的README：

Run with Docker Environment (Recommend)

```
docker pull sandai/magi:latest

docker run -it --gpus all --privileged --shm-size=32g --name magi --net=host --ipc=host --ulimit memlock=-1 --ulimit stack=6710886 sandai/magi:latest /bin/bash
```

Run with Source Code

```
# Create a new environment
conda create -n magi python==3.10.12

# Install pytorch
conda install pytorch==2.4.0 torchvision==0.19.0 torchaudio==2.4.0 pytorch-cuda=12.4 -c pytorch -c nvidia

# Install other dependencies
pip install -r requirements.txt

# Install ffmpeg
conda install -c conda-forge ffmpeg=4.4
```

```
# For GPUs based on the Hopper architecture (e.g., H100/H800), it is recommended to install
MagiAttention(https://github.com/SandAI-org/MagiAttention) for acceleration. For non-Hopper
GPUs, installing MagiAttention is not necessary.
git clone git@github.com:SandAI-org/MagiAttention.git
cd MagiAttention
git submodule update --init --recursive
pip install --no-build-isolation .
```

最后有一个从源码编译 flash-attn的办法，会在当前系统环境下链接本地 glibc。

```
pip uninstall -y flash-attn
pip install flash-attn==2.4.2 --no-build-isolation --no-cache-dir
```

但是一直卡住,，可能是显卡和 CPU不够：

```
DEPRECATION: Building 'flash-attn' using the legacy setup.py bdist_wheel mechanism, which
will be removed in a future version. pip 25.3 will enforce this behaviour change. A possible
replacement is to use the standardized build interface by setting the --use-pep517 option,
(possibly combined with --no-build-isolation), or adding a pyproject.toml file to the source
tree of 'flash-attn'. Discussion can be found at https://github.com/pypa/pip/issues/6334
Building wheel for flash-attn (setup.py) ... /
```

执行free -h 查看内存和swap空间：

```
(magi_try) root@7s6go2hlu6o82-0:/duwenqing/JIANGQINRU/MAGI-1# free -h
              total        used        free      shared  buff/cache   available
Mem:          503Gi       146Gi       337Gi       4.4Gi        18Gi       351Gi
Swap:            0B          0B          0B
```

发现是没有swap空间

尝试以下办法：

```
# 创建一个 8GB 的交换文件
sudo fallocate -l 8G /swapfile
# 设置权限
sudo chmod 600 /swapfile
# 格式化为 swap 空间
sudo mkswap /swapfile
# 启用 swap
sudo swapon /swapfile
```

```
sudo fallocate -l 8G /mnt/swapfile
sudo chmod 600 /mnt/swapfile
sudo mkswap /mnt/swapfile
sudo swapon /mnt/swapfile
```

均无果。

如果能使用docker环境应该是最方便的，如果不行，应该需要更好的服务器配置才能配上这个环境.....

这行：

```
Building wheel for flash-attn (setup.py) ... \
```

并不一定是“卡死”，有时是 **正在编译 CUDA 核心代码（非常耗内存 + CPU + GPU）**，但也可能是真的挂掉了。

运行以下命令看看是否还在用 CPU：

```
top -p $(pgrep -d, -f flash)
```

或者更保险一点：

```
ps aux | grep "gcc\|nvcc\|ninja"
```

如果看到有 gcc / nvcc / ninja 在跑、CPU 占用 > 50%，说明还在编译。
FlashAttention 会编译十几个 CUDA kernel，每个 kernel 编译可能要几分钟。

> ⚠️ 在 8GB 内存 + 0 swap 的情况下，编译 2.8.3 很容易被 kill 或卡死。

如果内存或 swap 不足，几乎必挂

系统当前状态：

```
MiB Mem : 1031704 total, 130073 free, 29171 used, 872458 buff/cache
MiB Swap: 0 total
```

👉 **Swap = 0**，这就意味着一旦内存被吃满（编译 flash-attn 大约需要 6～8GB），
系统会直接 **停住或被 OOM Kill**。

此时“卡住”其实是因为编译器进程被挂起或中止。

最后最后的解决办法，其实就是第一个， 在GitHub Releases 页面下载预编译文件：

第一次不成是因为系统版本不够。换成22.04就可以了。

但是当时版本选错了，还需要查看python的ABI状态：

```
python -c "import torch; print(torch.compiled_with_cxx11_abi())"
```

选择正确匹配的版本即可。

> 安装了与环境匹配的flash_attn后，主程序可以运行，但是运行到一半给出了一个报错，原因是MAGI-1的代码中定义的接口只和flash_attn2.4及以下的版本匹配，但是又没有与环境匹配的预编译wheel文件。
>
> 所以这个项目能跑的前提是：1、有一台有足够交换空间可以编译源码的机器；2、有一台可以运行docker的机器